گزارش فارسی تکلیف اول — یادگیری تقویتی

درس: یادگیری آماری پیشرفته و مدل‌سازی — ماژول A

دانشجو: امید شجاعیان

مبنای گزارش: چهار نوت‌بوک نهایی که در تاریخ ۱۲ اکتبر ۲۰۲۶ اجرا و در گیت‌هاب ذخیره شده‌اند.

صورت‌سؤال: تکلیف اول آزمایشگاه یادگیری تقویتی، اکتبر ۲۰۲۵.

خلاصه نتایج

در این تکلیف چهار آزمایش انجام شد: یادگیری کیو، سارسا، شبکه عمیق کیو و انتقال آن به محیط جدید.

تمرین	محیط	نتیجه واقعی
یادگیری کیو	دریاچه یخ‌زده، بدون لغزش	موفقیت **100.0٪**
یادگیری کیو	دریاچه یخ‌زده، با لغزش	موفقیت **68.8٪**
سارسا	دریاچه یخ‌زده، بدون لغزش	موفقیت **100.0٪**
شبکه عمیق کیو	فرود ماه‌نشین	میانگین پاداش **242.96**
تمرین امتیازی	حفظ تعادل میله	میانگین پاداش **143.71**؛ به حد نصاب نرسید

این اعداد از خروجی‌های ذخیره‌شده استخراج شده‌اند. توجه کن که «اجرا شدن کد» با «حل کردن محیط» تفاوت دارد.

۱. یادگیری کیو

هدف و روش

در محیط دریاچه یخ‌زده، عامل از خانه شروع باید به هدف برسد و در چاله‌ها نیفتد. محیط ۱۶ حالت و چهار حرکت دارد. برای هر جفت حالت و عمل، یک عدد در جدول کیو نگهداری می‌شود. در ابتدا این اعداد صفر هستند.

عامل با روش اکتشاف اپسیلون‌حریصانه گاهی حرکت تصادفی انجام می‌دهد و در سایر مواقع بهترین حرکت شناخته‌شده را انتخاب می‌کند.

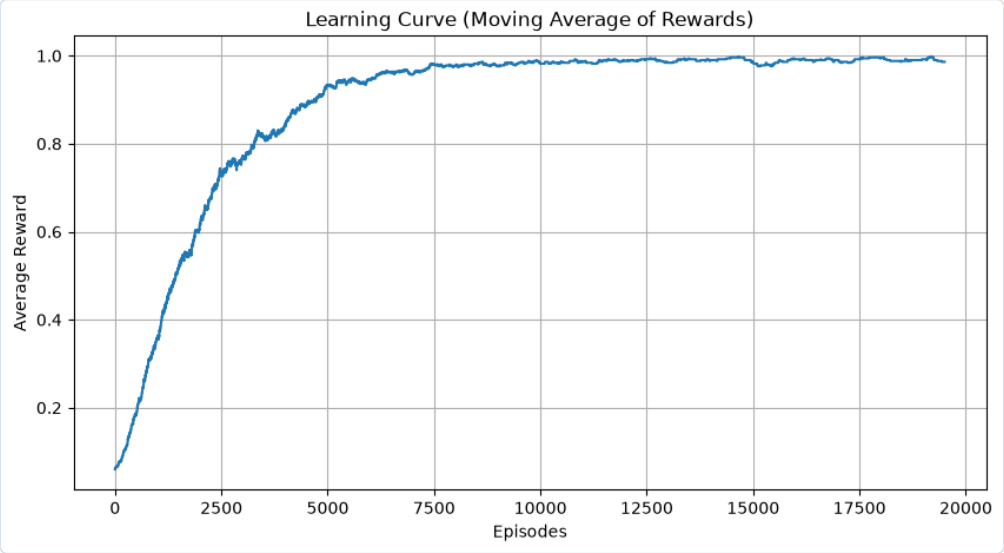
پارامتر	مقدار
نرخ یادگیری	۰٫۸
ضریب تنزیل	۰٫۹۵
تعداد اپیزود	۲۰٬۰۰۰
حداکثر قدم در هر اپیزود	۱۰۰
اپسیلون اولیه	۱
کمینه اپسیلون	۰٫۰۱
نرخ کاهش اپسیلون	۰٫۰۰۰۵

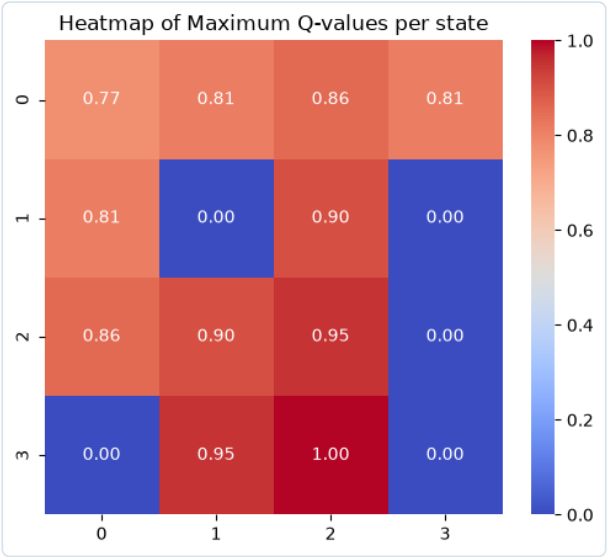
منطق به‌روزرسانی

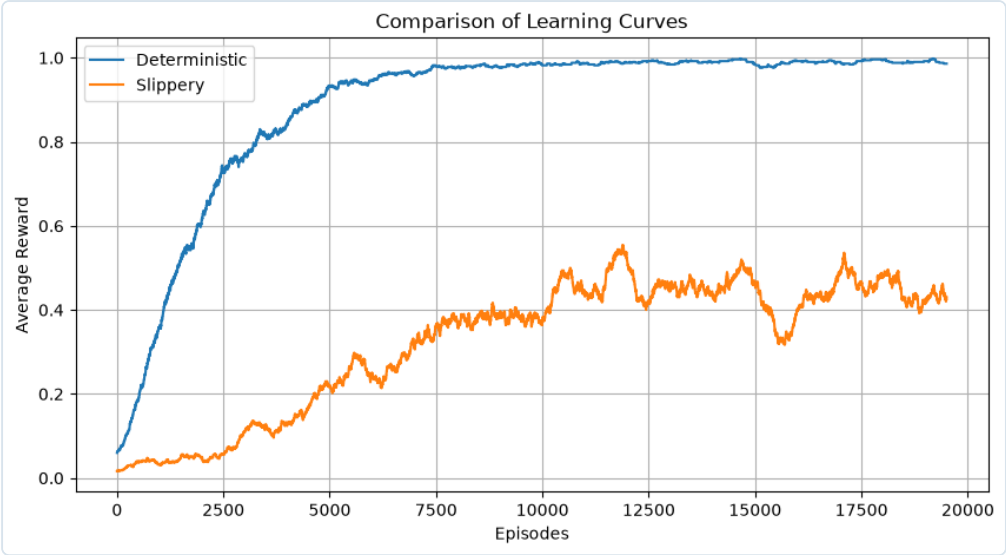
`Q(s,a) ← Q(s,a) + α × [r + γ max Q(s′,a′) − Q(s,a)]`

بخش داخل کروشه «خطای اختلاف زمانی» است: اختلاف میان پیش‌بینی قبلی و هدف جدید. در حالت پایانی، ارزش آینده صفر در نظر گرفته می‌شود. نرخ اکتشاف نیز به‌تدریج کاهش می‌یابد تا عامل از آزمودن حرکت‌های جدید به استفاده از تجربه برسد.

نمودارها و نتایج







سیاست حریصانه پس از آموزش در **100.0٪** از ۵۰۰ اپیزود ارزیابیِ بدون لغزش و **68.8٪** از ۵۰۰ اپیزود ارزیابیِ لغزنده موفق شد.

برداشت امتحانی: وقتی حرکت‌ها قطعی نیستند، یک تصمیم ظاهراً درست ممکن است عامل را به مسیر خطرناک ببرد. بنابراین سیاست یادگرفته‌شده و نرخ موفقیت در دو محیط متفاوت است. این نتیجه مربوط به همین اجرای ثبت‌شده است؛ نه میانگین چند اجرای مستقل.

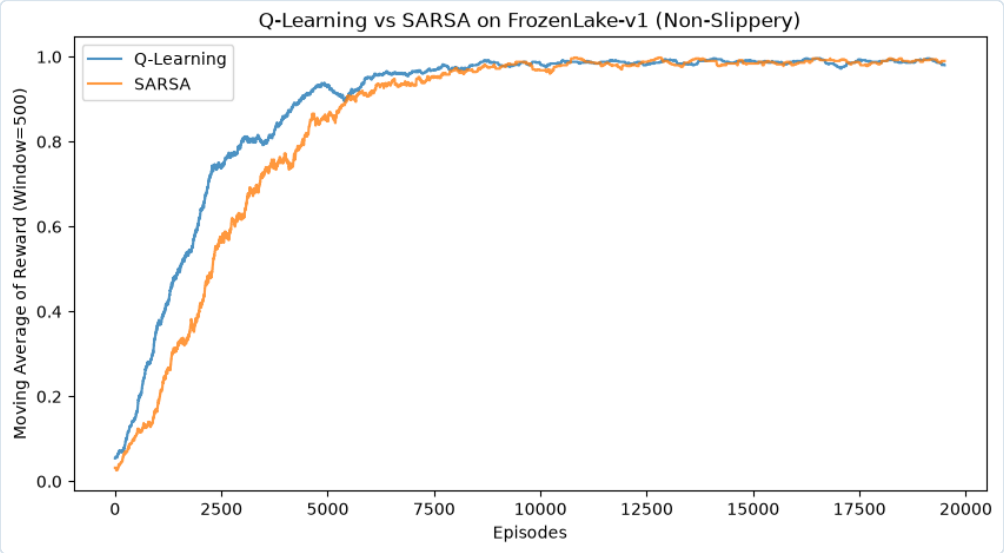
۲. سارسا و مقایسه آن با یادگیری کیو

تفاوت اصلی

سارسا یک روش **درون‌سیاستی** است؛ یعنی مقدار حالت را بر اساس عمل بعدی که واقعاً سیاست فعلی انتخاب می‌کند به‌روزرسانی می‌کند:

`Q(s,a) ← Q(s,a) + α × [r + γ Q(s′,a′) − Q(s,a)]`

اما یادگیری کیو **برون‌سیاستی** است و به‌جای عمل انتخاب‌شده، بیشترین ارزشِ اعمال ممکن را برای حالت بعدی به کار می‌برد. این تفاوت مهم‌ترین نکته نظری تمرین است.



معیار	سارسا	یادگیری کیو
میانگین پاداش ۵۰۰ اپیزود پایانی آموزش	0.990	0.980
موفقیت سیاست حریصانه در ۳۰۰ ارزیابی	100.0٪	100.0٪

هر دو در ارزیابیِ محیط قطعی به موفقیت ۱۰۰٪ رسیدند. برتری جزئی میانگین آموزش سارسا در این اجرا، به معنای بهتر بودن قطعی این الگوریتم در همه شرایط نیست.

۳. شبکه عمیق کیو

مسئله و معماری

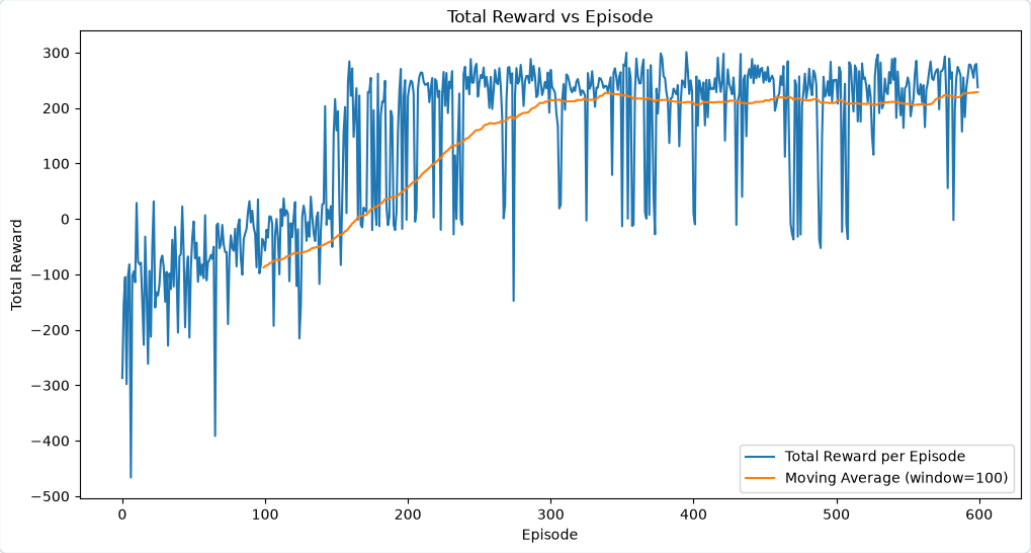
برای فضای حالت پیوسته ماه‌نشین، جدول ساده کیو مناسب نیست. در این تمرین یک شبکه عصبی با **۸ ورودی، دو لایه ۱۲۸تایی** و **۴ خروجی** ساخته شد. هر خروجی ارزش یکی از چهار عمل ممکن را تخمین می‌زند.

سه جزء مهم وجود دارد:

- حافظه تجربه، که انتقال‌های گذشته را نگه می‌دارد و نمونه‌های تصادفی می‌دهد.
- شبکه اصلی، که پارامترهایش با خطای یادگیری به‌روزرسانی می‌شود.
- شبکه هدف، که آهسته‌تر تغییر می‌کند و هدف‌های یادگیری را پایدارتر نگه می‌دارد.

پارامترها و آموزش

مدل با ۶۰۰ اپیزود، ضریب تنزیل ۰٫۹۹، دسته‌های ۱۲۸تایی، حافظه ۱۰٬۰۰۰تایی، نرخ یادگیری ۰٫۰۰۰۵ و به‌روزرسانی نرم شبکه هدف با ضریب ۰٫۰۰۵ آموزش دید. هدف یادگیری از رابطه بلمن و خطای از نوع هیوبر به دست می‌آید.



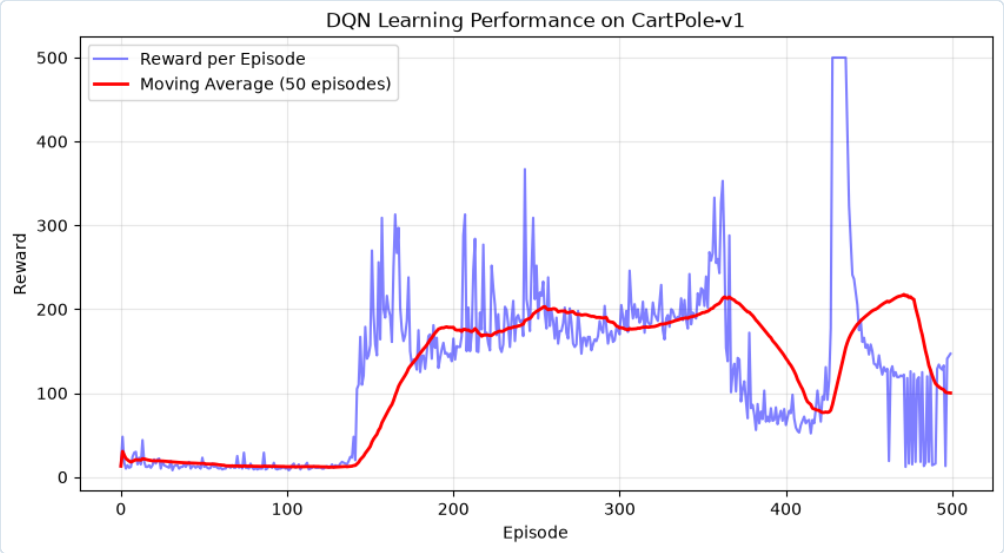
نتیجه: میانگین پاداش **242.96** و انحراف معیار **56.69** در ۱۰۰ اپیزود ارزیابی حریصانه ثبت شد. این نشان‌دهنده یادگیری رفتار مؤثر در این اجراست، اما به معنای موفق بودن تمام فرودها نیست.

نسخه محیط در کد نهایی، نسخه سوم ماه‌نشین است.

۴. تمرین امتیازی: انتقال شبکه عمیق کیو

در محیط حفظ تعادل میله، مشاهده چهار مؤلفه دارد و فقط دو عمل ممکن است. شبکه به ساختار **۴ ← ۱۲۸ ← ۱۲۸ ← ۲** تغییر یافت. پاداش هر قدمِ حفظ تعادل یک واحد است و سقف پاداش هر اپیزود ۵۰۰ است.

مدل با ۵۰۰ اپیزود، نرخ یادگیری ۰٫۰۰۰۱ و اکتشاف کاهشی آموزش دید.



در ۱۰۰ اپیزود ارزیابی، **میانگین 143.71 و انحراف معیار 3.93** ثبت شد. معیار معمول حل این محیط، میانگین حداقل ۴۷۵ در ۱۰۰ اپیزود است.

نتیجه علمی: این عامل در اجرای نهایی به معیار حل محیط نرسیده است. نمودار آموزش ممکن است اپیزودهای با پاداش بالا داشته باشد؛ اما این موضوع نمی‌تواند جای ارزیابی مستقل را بگیرد.

جمع‌بندی برای امتحان

یادگیری کیو و سارسا هر دو در محیط ساده و قطعی موفق شدند، ولی شیوه انتخاب هدف یادگیری در آن‌ها متفاوت است. شبکه عمیق کیو با شبکه عصبی، حافظه تجربه و شبکه هدف به مسئله‌های دارای حالت پیوسته گسترش می‌یابد. در تمرین امتیازی دیدیم که **اجرای درست برنامه تضمین‌کننده کیفیت بالای سیاست نیست**.

این گزارش بر اساس یک اجرای نهایی از هر آزمایش است؛ آزمایش چندبذری یا آزمون معنی‌داری آماری روی برتری الگوریتم‌ها انجام نشده است.

منابع

صورت‌سؤال رسمی تکلیف اول استاد (اکتبر ۲۰۲۵) و چهار نوت‌بوک اجراشده پوشه `moduleA/Assignment1` در مخزن گیت‌هاب. شکل‌ها مستقیماً از خروجی تصویری همان نوت‌بوک‌ها استخراج شده‌اند.