گزارش فارسی تکلیف اول

مدل‌های خطی تعمیم‌یافته | سه تمرین و نتایج اجراشده

ماژول B • امید شجاعیان زنجانی • ۱۲ اکتبر ۲۰۲۶ • ترجمه فارسی گزارش نهایی انگلیسی

وضعیت تحلیل، منشأ داده‌ها و بازتولیدپذیری

این گزارش حاصل تحلیل اجراشده و بررسی‌شده است. هر سه تمرین در محیط تحلیل مجدداً برازش شده‌اند و نوت‌بوک اصلاح‌شده خروجی‌های اجرایی ذخیره‌شده را در خود دارد. تمرین‌های ۱ و ۳ از استخراجِ سطربه‌سطرِ ستون‌های موردنیاز مجموعه‌داده‌های CSV موجود در مخزن عمومی گیت‌هاب استفاده می‌کنند: **395** دانش‌آموز و **740** رکورد غیبت. تمرین ۲ از جدول کامل فراوانی‌های Sex × Race × Education با **30** خانه و مجموع **32,561** مشاهده استفاده می‌کند که از آرشیو گیت‌هاب بازسازی شده است. این‌ها زیرمجموعه‌های شفاف از داده‌های واقعی‌اند، نه داده‌های ساختگی. نام فایل‌های منبع، نحوه استخراج و ورودی‌های بازیابی‌شده در پوشه شواهد پروژه موجود است.

موضوع: مدل‌های خطی تعمیم‌یافته، شامل سه تمرین. استاد: Giulia Vannucci. اقلام لازم برای تحویل: گزارش، فایل کد و یادداشت فردی یا گروهی‌بودن کار. کد تحلیل: assignment1.ipynb. هیچ نتیجه عددی ساختگی در گزارش وارد نشده است. روابط گزارش‌شده از نوع همراهی آماری‌اند، نه علت و معلول.

تمرین ۱ — رگرسیون لجستیک چندجمله‌ای و ترتیبی

پرسش پژوهش و آماده‌سازی داده‌ها

در داده‌های عملکرد درسی دانش‌آموزان (درس ریاضی)، نمره نهایی G3 به سه دسته تبدیل شده است: «پایین» از 0–9، «متوسط» از 10–14 و «بالا» از 15–20. نمره ۱۰ مرز معمول قبولی است و نمره ۱۵ موفقیت تحصیلی بالاتر را متمایز می‌کند. متغیرهای توضیحی همان متغیرهای نسخه قبلی پروژه‌اند: زمان مطالعه، تعداد مردودی‌های قبلی، غیبت، تحصیلات مادر و تحصیلات پدر. سطح ترتیبی تحصیلات والدین و زمان مطالعه به شکل متغیر عددی وارد شده است؛ بنابراین فرض می‌شود تأثیر افزایش یک سطح بر لگاریتم نسبت شانس‌ها خطی باشد.

مدل‌ها و نتایج

در رگرسیون لجستیک چندجمله‌ای، گروه «پایین» مبناست و نسبت شانس «متوسط در برابر پایین» و «بالا در برابر پایین» جداگانه برآورد می‌شود. رگرسیون لجستیک ترتیبی با فرض شانس‌های متناسب، برای هر متغیر توضیحی یک شیب مشترک در هر دو مرز تجمعی نمره و آستانه‌های عرض از مبدأ جداگانه در نظر می‌گیرد.

معیار	مدل چندجمله‌ای	مدل ترتیبی
تعداد مشاهده	395	395
لگاریتم درست‌نمایی	-370.05	-375.65
AIC	764.109	765.309

ضرایب ثبت‌شده در مدل ترتیبی عبارت‌اند از: مردودی قبلی 0.9290- با $p<0.001$ و نسبت شانس 0.395 ؛ غیبت 0.0299- با $p=0.021$ و نسبت شانس تقریبی 0.971 برای افزایش یک واحد غیبت؛ و تحصیلات مادر 0.2672+ با $p=0.024$ و نسبت شانس تقریبی 1.306. در این مدل، ضریب مثبت به معنای افزایش شانس قرارگرفتن در دسته‌های نمره بالاتر است و ضریب منفی عکس آن را نشان می‌دهد. در مدل چندجمله‌ای، ضرایب مردودی قبلی نیز منفی هستند: 0.8134- برای متوسط در برابر پایین و 1.7377- برای بالا در برابر پایین.

بررسی فرض اساسی و انتخاب مدل نهایی

نسخه اولیه مخزن، مقایسه درست‌نمایی مدل چندجمله‌ای با مدل ترتیبی را با مقدار $p=0.0476$ به‌عنوان آزمون «شانس‌های متناسب» گزارش می‌کرد. این مقایسه برای این دو خانواده مدل، که عموماً با این نوع پیش‌بین‌ها مدل‌های تودرتوی مناسب آزمون نسبت درست‌نمایی نیستند، آزمون معتبری به شمار نمی‌رود. نوت‌بوک اصلاح‌شده، دو مدل لجستیک تجمعی را برازش کرده و برابری شیب‌ها را با یک آزمون والد مشترک از نوع برانت، با برآورد واریانس مقاوم (ساندویچی)، آزموده است:

$$\chi^2(5) = 9.132 \quad | \quad p = 0.103924$$

پس در سطح معنی‌داری پنج درصد، فرض شانس‌های متناسب **رد نمی‌شود**؛ البته معنادار نبودن آزمون به معنای اثبات یکسان‌بودن شیب‌ها نیست. معیار AIC اندکی مدل چندجمله‌ای را ترجیح می‌دهد (764.109 در مقابل 765.309 ؛ اختلاف 1.20)؛ در مقابل، معیار BIC مدل ترتیبیِ کم‌پارامترتر را ترجیح می‌دهد (793.161 در برابر 811.856). به دلیل سادگی و قابلیت تفسیر، مدل ترتیبی انتخاب نهایی قابل دفاعی است؛ البته قدرت آزمون و برازش مدل همچنان باید با احتیاط تفسیر شوند.

نتیجه تمرین ۱: مردودی و غیبت بیشتر با عملکرد ضعیف‌تر در ریاضی همراه‌اند، و تحصیلات بالاتر مادر با عملکرد بهتر همراه است. آزمون مشترک فرض شانس‌های متناسب در سطح پنج درصد معنی‌دار نبود و BIC نیز مدل ترتیبی را ترجیح می‌دهد.

تمرین ۲ — مدل‌های لگ‌خطی و هم‌ارزی با رگرسیون لجستیک

داده‌ها و مدل‌های برازش‌شده

داده‌های UCI Adult برحسب جنسیت (زن/مرد)، نژاد (پنج دسته)، و تحصیلاتِ بازکدگذاری‌شده (دبیرستان، کالج، تحصیلات پیشرفته) طبقه‌بندی شدند. خروجی گیت‌هاب جدول کامل $3 \times 5 \times 2$ با ۳۰ فراوانی و مجموع 32,561 را در اختیار می‌گذارد. بازسازی این جدول همه اطلاعات لازم برای برازش مدل‌های لگ‌خطی سلسله‌مراتبی را حفظ می‌کند؛ ولی به معنی دسترسی مستقیم به رکوردهای فردی فایل CSV نیست.

سه مدل لگ‌خطی پواسونِ تودرتو مقایسه شدند: استقلال متقابل [E][R][S]، استقلال شرطی [SE][RE] (جنسیت مستقل از نژاد به شرط تحصیلات)، و مدل دارای همه ارتباطات دوتایی [SR][SE][RE]. آزمون‌های کای‌دوی نسبت درست‌نمایی با اختلاف انحراف مدل‌ها و درجات آزادی آن‌ها انجام شدند.

مدل	انحراف	درجه آزادی باقیمانده	مقدار p برازش
استقلال متقابل	1104.683	22	9.8×10^{-220}
استقلال شرطی	436.612	12	6.56×10^{-86}
تمام ارتباطات دوتایی	19.297	8	0.0133

مقایسه مدل‌های تودرتو	کای‌دو نسبت درست‌نمایی	درجه آزادی	مقدار p
استقلال متقابل ← استقلال شرطی	668.071	10	4.5×10^{-137}
استقلال شرطی ← همه ارتباطات دوتایی	417.315	4	5×10^{-89}

مدل دارای تمام ارتباطات دوتایی نسبت به استقلال شرطی بسیار بهتر است: $\chi^2(4)=417.315$ و $p \approx 5.04\times10^{-89}$. بااین‌حال، انحراف آن 19.297 با ۸ درجه آزادی و $p=0.01335$ است؛ بنابراین آزمون برازش کلی در سطح ۵٪ رد می‌شود و وجود برهم‌کنش سه‌طرفه مطرح است. هیچ‌کدام از سه مدل غیراشباعِ تعیین‌شده، معیار سختگیرانه برازش در سطح پنج درصد را برآورده نمی‌کنند؛ مدل تمام ارتباطات دوتایی فقط نسبت به دو مدل دیگر بهتر است. مدل اشباع [SRE] جدول را دقیق بازسازی می‌کند، ولی درجه آزادی باقیمانده‌ای برای سنجش برازش ندارد.

هم‌ارزی رسمی با رگرسیون لجستیک دودویی

اگر «مرد» با عدد ۱ کدگذاری شود، رگرسیون لجستیک جنسیت برحسب اثرات اصلی نژاد و تحصیلات، از لحاظ ریاضی با مدل لگ‌خطیِ شامل [SR]، [SE] و [RE] معادل است. مؤلفه [RE] توزیع حاشیه‌ای نژاد–تحصیلات را آزاد می‌گذارد، و مؤلفه‌های [SR] و [SE] جمع‌پذیری اثرات در لگاریتم نسبت شانس جنسیت را به وجود می‌آورند.

ضریب	لجستیک دودویی، ضریب (SE)	پواسون لگ‌خطی، ضریب (SE)
Intercept	+0.6642 (0.120)	+0.6642 (0.120)
Race: Asian-Pac-Islander	+0.1651 (0.135)	+0.1651 (0.135)
Race: Black	-0.4854 (0.122)	-0.4854 (0.122)
Race: Other	-0.1194 (0.171)	-0.1194 (0.171)
Race: White	+0.2941 (0.118)	+0.2941 (0.118)
Education: College	-0.3892 (0.032)	-0.3892 (0.032)
Education: HighSchool	-0.0906 (0.031)	-0.0906 (0.031)

بیشترین اختلاف قدر مطلق برآوردهای هفت ضریب تقریباً 1.3×10^{-14} بوده است؛ یعنی اختلافی در حد گردکردن محاسبات ممیز شناور. خطاهای استاندارد هم تا دقت نمایش‌داده‌شده یکسان‌اند. این نتیجه هم‌ارزی جبری مدل‌ها را روی جدول بازسازی‌شده تأیید می‌کند؛ بااین‌حال، محدودیت برازش کلی مدل ارتباطات دوتایی پابرجاست.

مثال تفسیر: با ثابت‌بودن تحصیلات، ضریب لگاریتم نسبت شانس «مرد بودن» برای گروه Black نسبت به دسته مرجع Amer-Indian-Eskimo برابر 0.4854- (نسبت شانس تقریبی 0.616) است. این مقدار فقط ترکیب نسبی جنسیت در نمونه را توصیف می‌کند و تبیین رفتار فردی یا علت نیست.

تمرین ۳ — ساعات غیبت، بیش‌پراکندگی و صفرهای ساختاری

بررسی توصیفی و مدل‌های نامزد

داده‌های غیبت از کار (N=740) بررسی شد. متغیر پاسخ، تعداد ساعات غیبت است که مانند داده شمارشی مدل شده است. آمار تأییدشده: میانگین 6.9243، واریانس نمونه 177.7155 و تعداد صفرهای مشاهده‌شده 44 (معادل 5.95%). نسبت واریانس به میانگین حدود 25.67 و نسبت کای‌دوی پیرسون به درجه آزادی باقیمانده در مدل پواسون 22.127 است که بیش‌پراکندگی بسیار شدید را نشان می‌دهد. مدل پواسونِ برازش‌شده فقط 1.754 صفر پیش‌بینی می‌کند. متغیرهای توضیحی عبارت‌اند از فاصله منزل تا محل کار، سن، سابقه خدمت و تحصیلات. کد «علت غیبت» کنار گذاشته شده، چون ممکن است وضعیت غیبت را خود افشا کند و موجب نشت اطلاعات شود.

چهار مدل برازش شد: پواسون، دوجمله‌ای منفی نوع دوم (NB2) با پارامتر پراکندگی برآوردشده، پواسون با صفر اضافی (ZIP) و دوجمله‌ای منفی با صفر اضافی (ZINB2). در دو مدل صفرافزا، برای جزء «صفر ساختاری» فقط عرض از مبدأ در نظر گرفته شد تا تعداد پارامترها بی‌دلیل زیاد نشود. هر چهار مدل همگرا شدند و درست‌نمایی متناهی داشتند. ستون‌های بازیابی‌شده همچنین معیار AIC پواسون و NB2 را، تا حد گردکردن، مشابه خروجی آرشیوی بازتولید کردند.

مدل همگرا	AIC	BIC	تعداد صفر پیش‌بینی‌شده
NB2	4,423.985	4,451.625	106.008
ZINB2	4,425.985	4,458.232	106.008
ZIP	9,755.493	9,783.133	44.765
پواسون	10,133.249	10,156.282	1.754

انتخاب مدل و تعبیر ضرایب

NB2 کمترین AIC و BIC را میان چهار مدل همگرا دارد و انتخاب نهایی است. مدل ZINB2 در مقایسه با NB2 تقریباً هیچ بهبودی در درست‌نمایی ایجاد نمی‌کند؛ اما یک پارامتر اضافه دارد و به همین دلیل AIC آن تقریباً دقیقاً دو واحد بالاتر است. نسبت شانس مؤلفه صفر ساختاری در ZINB2 حدود 1.26×10^{-8} است؛ یعنی احتمال صفر اضافیِ جداگانه در عمل به صفر نزدیک می‌شود. مدل ZIP تعداد صفرهای مشاهده‌شده را نزدیک‌تر پیش‌بینی می‌کند (44.77 در برابر 44)، اما برازش آن برای کل توزیع بسیار ضعیف‌تر است (AIC≈9755.49). از طرف دیگر، NB2 شمار صفرها را بیش‌ازحد پیش‌بینی می‌کند (106.01 در برابر 44)؛ این یک محدودیت برازش است که باید پذیرفته شود. صرف دیدن صفرهای زیاد، وجود فرایند صفر ساختاری را ثابت نمی‌کند.

در **جزء شمارشی**، عبارت $\exp(\beta)$ ضریب ضربیِ نرخ مورد انتظار فرایند شمارشیِ نهفته را در ازای افزایش یک واحد متغیر توضیحی (با ثابت‌بودن سایر متغیرها) بیان می‌کند. در **جزء صفرافزا**، عبارت $\exp(\gamma)$ نسبت شانس قرارگرفتن در گروه نهفته‌ای را نشان می‌دهد که به‌طور ساختاری همیشه صفر دارد. در ZIP/ZINB صفر می‌تواند از هر یک از این دو جزء تولید شود. وقتی جزء صفرافزا فقط عرض از مبدأ دارد، مدل تنها یک احتمال مبنای صفر ساختاری را برآورد می‌کند و اثر متغیرها بر عضویت در این گروه را به دست نمی‌دهد.

نتیجه نهایی: مدل دوجمله‌ای منفی در مقایسه با چهار مدل همگرا، بر اساس AIC و BIC برتر است. در ZIP نسبت شانسِ جزء صفرافزا برابر 0.06235 است (احتمال صفر ساختاری تقریباً 5.87%) و نسبت نرخِ فاصله در جزء شمارشیِ آن تقریباً 0.9870 است. در ZINB2 احتمال صفر اضافی عملاً ناپدید می‌شود؛ پس این داده‌ها از مکانیسم جداگانه صفر ساختاری در مدل برازش‌شده پشتیبانی نمی‌کنند. محدودیت باقی‌مانده: NB2 صفرهای بیشتری نسبت به مقدار مشاهده‌شده پیش‌بینی می‌کند.

محدودیت‌ها، تحویل و بازتولید

- فایل‌های ستون‌های استخراج‌شده و جدول فراوانی ۳۰خانه‌ای در بسته پروژه وجود دارند و هر سه تمرین را می‌توان بر اساس آن‌ها اجرا کرد؛ اجرای همان مشخصات مدل روی CSVهای اصلی گیت‌هاب نیز پشتیبانی می‌شود.
- آزمون‌ها و بازه‌های اطمینان، همراهی آماری را توصیف می‌کنند نه رابطه علت و معلولی را. کدگذاری عددی برخی متغیرهای ترتیبی نوعی ساده‌سازی علمی است.
- استاد یک PDF شامل هر سه تمرین، یک فایل کد و یادداشت درباره فردی یا گروهی‌بودن کار می‌خواهد. اگرچه ابتدای دستورالعمل عبارت «دو تمرین» دیده می‌شود، متن تمرین‌ها و فهرست تحویل صریحاً سه تمرین دارند.
- هر سه تمرین با ورودی‌های کافیِ بازیابی‌شده اجرا شده‌اند و نوت‌بوک شامل نتایج، وضعیت همگرایی و تشخیص‌هاست. محدودیت آن است که برای بخشی از تحلیل از استخراج ستون‌های موردنیاز استفاده شده است، نه فایل‌های CSV خام و کامل.

این سند ترجمه فارسی گزارش انگلیسی نهایی پروژه است. اعداد و نتایج آماری از همان گزارش گرفته شده‌اند. توضیحات، همبستگی آماری را نشان می‌دهند و دلالت بر علیت ندارند.